

# Análisis de Datos de Fórmula 1 mediante Databricks: Segmentación de Escuderías y Patrones de Rendimiento Histórico

Kevin Esquivel, Abigail Simmons, Luis Solis, Sergio Villarreal  
Universidad Tecnológica de Panamá

Facultad de Ingeniería de Sistemas Computacionales

Asignatura: Análisis de Datos y Toma de Decisiones para Computación

Profesor: Javier Sánchez Galán | Grupo IIL-133 | I semestre de 2026

**Resumen**— Este documento presenta el análisis de datos históricos y ficticios de la Fórmula 1 (1950-2025) con el objetivo de perfilar el rendimiento deportivo y financiero de escuderías y pilotos. Se empleó una metodología de extracción, transformación y carga (ETL) utilizando PySpark y SparkSQL en la plataforma Databricks. La analítica avanzada incluyó la aplicación del algoritmo K-means para segmentar 21 escuderías en tres perfiles. Adicionalmente, se consolidó un Dashboard público compuesto por indicadores clave de rendimiento (KPIs) y gráficos referentes a los pilotos, los patrocinios y la influencia meteorológica en los circuitos.

**Palabras clave**— Databricks, PySpark, SparkSQL, K-means, Formula 1, clustering, dashboard.

## I. INTRODUCCIÓN

La Fórmula 1 representa un entorno altamente competitivo donde convergen el rendimiento deportivo, la eficiencia tecnológica y la gestión financiera. Este ecosistema genera volúmenes masivos de información, convirtiéndolo en un dominio idóneo para el análisis de datos. La pregunta de investigación central de este estudio evalúa la relación entre la inversión de los patrocinadores, el presupuesto de las escuderías y los resultados obtenidos en pista. Para responder a esta interrogante, se procesó un conjunto de datos estructurados utilizando Databricks [1] hasta generar un Dashboard dinámico.

## II. DATOS Y PREPARACIÓN

El conjunto de datos original consta de 12 tablas relacionales generadas mediante la herramienta Mockaroo [2], abarcando información sintética del periodo 1950–2025. El proceso de ingesta se ejecutó en Databricks, donde se estableció un clúster de procesamiento. La preparación incluyó la verificación exhaustiva de los tipos de datos (esquemas), el manejo de valores nulos y el conteo de registros para asegurar la integridad referencial. A través de PySpark, las tablas fueron limpiadas para el posterior análisis estadístico en el notebook 3, 4 y 5 y el modelado del Dashboard en el notebook 6.

## III. ANÁLISIS EXPLORATORIO Y SQL

El análisis exploratorio de datos (EDA), documentado en el notebook 04, se ejecutó mediante consultas en SparkSQL para extraer estadísticas descriptivas. Se evaluó el rendimiento histórico, determinando la distribución de puntos por piloto y escudería. Entre las cifras concretas extraídas destacan: el registro de 50 pilotos pertenecientes a 21 escuderías únicas, a lo largo de 120 carreras históricas y una inversión global que asciende a 4903.6 millones de USD en patrocinios. Estas métricas iniciales permitieron identificar patrones de dominio de ciertos equipos y la concentración de capital.

## IV. DISEÑO DEL DASHBOARD

Para la visualización, se estructuraron 5 tablas resumen

(documentadas en el notebook 06) diseñadas para alimentar de forma directa la interfaz gráfica. El Dashboard presenta 4 KPIs principales (total de pilotos, escuderías, carreras e inversión en patrocinios) en la sección superior. Incorpora 4 gráficos interactivos que detallan los mejores pilotos, patrocinios por sector, perfilado de escuderías y probabilidad de lluvia en circuitos. La herramienta incluye 2 filtros (Año y Región) y texto de interpretación dinámico para facilitar la comprensión. El resultado fue publicado como un Dashboard de acceso público [1].

## V. ANALÍTICA AVANZADA

Se implementó un modelo de aprendizaje automático no supervisado para segmentar las 21 escuderías participantes. Se utilizó el algoritmo K-means con  $k=3$ , importado de la biblioteca scikit-learn [3]. Las variables predictoras seleccionadas para el clustering fueron el presupuesto total de la escudería, el total de puntos obtenidos y el monto aportado por patrocinio. El modelo convergió en tres perfiles definidos: 1) Alto rendimiento deportivo; 2) Alto presupuesto con bajo rendimiento; y 3) Bajo presupuesto y bajo rendimiento.

## VI. RESULTADOS Y DISCUSIÓN

Los resultados establecen a Daniel Ricciardo como el piloto líder histórico con 412 puntos acumulados. A nivel financiero, el sector de Seguros domina el mercado de patrocinios con una inyección de 909.71 millones de USD, seguido por el sector Banca. En variables ambientales, el circuito de Marina Bay destaca como el más propenso a presentar precipitaciones (65.6%). El hallazgo analítico clave demuestra empíricamente que el presupuesto no garantiza el éxito deportivo; el modelo de clustering agrupó a equipos con máxima inversión que fueron relegados a posiciones inferiores frente a escuderías más eficientes. (Ver figuras en la página 2).

## VII. CONCLUSIONES

El procesamiento estructurado a través de seis notebooks permitió consolidar un ciclo ETL y analítico completo. Los resultados obtenidos evidencian mediante clustering que un mayor presupuesto no garantiza el éxito deportivo, y confirman el dominio financiero del sector seguros. Esta metodología garantiza datos optimizados para alimentar Dashboard interactivos eficientemente.

## REFERENCIAS

- [1] Databricks, "Databricks Free Edition," 2024. [En línea]. Disponible: <https://www.databricks.com/learn/free-edition>
- [2] Mockaroo, "Random Data Generator and API Mocking Tool," 2024. [En línea]. Disponible: <https://www.mockaroo.com/>
- [3] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," J. Mach. Learn. Res., vol. 12, pp. 2825–2830, 2011.
- [4] Apache Spark, "PySpark Documentation," Apache Software Foundation, 2024. [En línea]. Disponible: <https://spark.apache.org/docs/latest/api/python/>

## RESULTADOS GRÁFICOS Y SÍNTESIS DEL DASHBOARD

Figuras generadas a partir de las tablas resumen de los notebooks 05 y 06.  
Universidad Tecnológica de Panamá - Análisis de Datos y Toma de Decisiones para Computación

| Total de pilotos | Total de Escuderías | Total de Carreras Historicamente | Total de Patrocinio (millones USD) |
|------------------|---------------------|----------------------------------|------------------------------------|
| 50               | 21                  | 120                              | 4903.6                             |




Figura #1: Top 10 pilotos con mayor acumulación de puntos.  
El filtro por año muestra el ranking por temporada.




Figura #2. Distribución del patrocinio en F1 por sector. Seguros y Banca concentran el 35% de la inversión.



Figura #3. Segmentación K-means ( $k=3$ ). Tres perfiles: alto rendimiento, alto presupuesto/bajo rendimiento, y bajo presupuesto/rendimiento.




Figura #4. Probabilidad histórica de lluvia por circuito. Marina Bay lidera con 67%, Spa-Francorchamps con 54%.

**Análisis avanzado (K-means):**  $k=3$  clusters | Variables: presupuesto, puntos obtenidos, patrocinio | Escuderías: 21

**Interpretación:** El clustering revela que el presupuesto no garantiza el éxito deportivo. Escuderías con alta inversión pueden tener bajo rendimiento, mientras equipos con presupuesto moderado alcanzan los mejores resultados. El Dashboard permite explorar estos patrones de forma interactiva mediante filtros por año y región, facilitando la toma de decisiones para un público no técnico.